

Лабораторная работа №2: Классификация

Цель работы

Пройти полный цикл решения задачи классификации: от анализа данных и построения baseline до сравнения нескольких алгоритмов, анализа метрик, ошибок и важности признаков.

Задание

Данные

Используйте датасет **Titanic Dataset**.

Ссылка: <https://www.kaggle.com/datasets/yasserh/titanic-dataset>

Целевая переменная — **Survived**: необходимо предсказать, выжил пассажир (1) или нет (0).

Проведите первичный анализ данных: изучите признаки, их типы, пропуски, дубликаты и распределение целевой переменной. Обратите внимание на признаки, которые требуют отдельной обработки, и на признаки, использование которых может привести к утечке информации или бессмысленному запоминанию объектов. После основных результатов должны быть **краткие содержательные выводы**.

Подготовка данных и выборки

Подготовьте данные к обучению моделей. Обработайте пропущенные значения и категориальные признаки. Выбранные способы обработки необходимо кратко обосновать.

Разделите данные на обучающую и тестовую части с сохранением соотношения классов. Зафиксируйте **random_state**. Все модели должны обучаться и оцениваться на одинаковом разбиении.

Тестовая выборка используется только для финальной оценки качества. Все преобразования, параметры которых вычисляются по данным, должны обучаться только на обучающей выборке.

Подумайте, для каких из используемых далее алгоритмов важно масштабирование признаков и почему.

Baseline и leaderboard

Перед обучением моделей постройте **Dummy baseline**, который всегда предсказывает наиболее частый класс. Рассчитайте для него те же метрики, что и для остальных моделей.

Основная метрика лабораторной и leaderboard — **F1-score** для класса **Survived** = 1. Она учитывает одновременно Precision и Recall и лучше одной Accuracy показывает качество бинарной классификации, когда классы представлены не одинаково.

Минимальный порог качества для лабораторной: **F1** > 0.70. Результат оценивается на единой тестовой выборке, одинаковой для всей группы.

Для leaderboard используется F1-score: чем выше значение, тем выше позиция. Подбирать решение непосредственно по тестовой выборке запрещено.

Метрики

Для оценки моделей используйте:

- Accuracy;
- Precision;
- Recall;
- F1-score.

Для каждой модели также постройте **confusion matrix**. Не ограничивайтесь выводом значений метрик. Объясните, какие ошибки совершает модель и чем различаются False Positive и False Negative в контексте этой задачи.

Модели

Необходимо обучить и сравнить следующие модели.

Decision Tree. Обучите дерево решений. Оцените качество модели и исследуйте feature importance. Сравните качество на обучающей и тестовой выборках. Сделайте вывод о наличии или отсутствии признаков переобучения.

Random Forest. Обучите случайный лес. Оцените его по тем же метрикам. Исследуйте feature importance и сравните наиболее важные признаки с результатами Decision Tree.

Gradient Boosting. Обучите градиентный бустинг. Оцените его качество и исследуйте feature importance. Сравните результат с Random Forest.

Support Vector Machine. Обучите метод опорных векторов. Подумайте, требуется ли масштабирование признаков для данного алгоритма и почему. Оцените модель по тем же метрикам.

K-Nearest Neighbors. Обучите KNN. Объясните, почему масштаб признаков особенно важен для алгоритма, основанного на расстоянии между объектами. Оцените модель по тем же метрикам.

Честное сравнение моделей

Все модели должны сравниваться в одинаковых условиях. Составьте итоговую таблицу с Accuracy, Precision, Recall и F1 для baseline и всех пяти моделей.

Определите, какие модели превзошли установленный порог качества. Объясните возможные причины различий между результатами моделей.

Feature Importance

Анализ важности признаков является обязательной частью работы для моделей, которые позволяют его получить.

Необходимо:

1. визуализировать важность признаков;
2. выделить наиболее важные признаки;
3. сравнить результаты Decision Tree, Random Forest и Gradient Boosting;
4. сопоставить важность признаков с выводами, сделанными при первичном анализе данных.

Можно ли утверждать, что важный для модели признак является причиной выживания пассажира? Объясните ответ.

Анализ ошибок

Для лучшей модели исследуйте confusion matrix подробнее. Определите, какие типы ошибок встречаются чаще и для каких групп пассажиров модель ошибается наиболее заметно.

Выберите несколько ошибочно классифицированных объектов и попробуйте объяснить возможные причины ошибок. Отдельно проверьте, не связано ли высокое качество модели с использованием признаков, которые фактически идентифицируют конкретного пассажира или содержат нежелательную информацию.