

Лабораторная работа №1: регрессия

Цель работы

Пройти полный цикл решения задачи регрессии: от первичного анализа данных и простого baseline до сравнения нескольких моделей и анализа результатов.

Минимальный порог качества: $RMSE < 0.70$.

Оценка проводится на единой скрытой тестовой выборке. Если $RMSE \geq 0.70$, работа получает не более 2 баллов и требует доработки.

Задание

Знакомство с данными

Перед обучением моделей необходимо исследовать датасет **Wine Quality** из UCI Machine Learning Repository.

Ссылка: <https://archive.ics.uci.edu/dataset/186/wine+quality>

Проведите первичный анализ данных, не ограничивайтесь таблицами и графиками. После основных результатов должны быть **краткие содержательные выводы**.

Например, недостаточно написать: «Корреляция alcohol и quality равна ...». Нужно объяснить, что эта зависимость означает в контексте задачи и стоит ли учитывать её при моделировании.

Подготовка выборок

Разделите данные на обучающую и тестовую части.

Тестовая выборка предназначена **только для финальной оценки качества модели**. Все решения, связанные с выбором модели, признаков и параметров, должны приниматься без использования ответов тестовой выборки.

Зафиксируйте `random_state`, чтобы эксперимент можно было воспроизвести.

Объясните:

- какой размер обучающей и тестовой выборки вы выбрали;
- почему был выбран именно такой способ разбиения;
- какие проблемы могут возникнуть, если многократно оценивать модели на одной и той же тестовой выборке.

Baseline

Перед использованием алгоритмов машинного обучения необходимо построить простое базовое решение — **baseline**.

В качестве baseline используйте предсказание одной константой для всех объектов.

Самостоятельно определите, какую константу разумно использовать для выбранной метрики.

Посчитайте качество baseline на тестовой выборке.

Baseline нужен для ответа на простой вопрос: действительно ли **обученная модель извлекает из признаков полезную информацию или её результат не лучше тривиального предсказания?**

Результат baseline обязательно должен присутствовать в итоговой таблице.

Метрики

Основная метрика лабораторной работы — **RMSE (Root Mean Squared Error)**.

Дополнительно необходимо рассчитать **MAE (Mean Absolute Error)**.

Для каждой модели в итоговой таблице должны быть указаны обе метрики.

Ответьте на вопросы:

- что показывает MAE;
- что показывает RMSE;
- почему RMSE сильнее реагирует на большие ошибки;
- почему для одной и той же модели значения MAE и RMSE могут заметно различаться.

Для leaderboard используется **RMSE**: чем меньше значение, тем лучше результат.

Модели

Необходимо обучить и сравнить следующие модели.

Линейная регрессия

Постройте модель линейной регрессии.

Проанализируйте полученный результат.

Исследуйте коэффициенты модели и определите признаки, которые оказывают наибольшее влияние на предсказание.

Обратите внимание: сравнивать абсолютные значения коэффициентов признаков, измеренных в совершенно разных масштабах, напрямую может быть некорректно.

Подумайте, требуется ли масштабирование данных и как оно влияет на интерпретацию коэффициентов.

Random Forest Regressor

Обучите случайный лес для решения той же задачи.

Получите предсказания и оцените модель по RMSE и MAE.

Исследуйте **feature importance**.

Определите наиболее важные признаки и сравните полученный результат с выводами, сделанными при первичном анализе данных и при работе с линейной регрессией.

Gradient Boosting Regressor

Обучите модель градиентного бустинга.

Оцените её по тем же метрикам.

Также проведите анализ **feature importance**.

Сравните важные признаки, найденные случайным лесом и градиентным бустингом.

Честное сравнение моделей

Все модели должны сравниваться в одинаковых условиях.

Нельзя использовать разные тестовые выборки для разных моделей.

Составьте итоговую таблицу вида:

Модель	RMSE	MAE
Baseline	...	...
Linear Regression	...	...
Random Forest	...	...
Gradient Boosting	...	...

Определите, какие модели превзошли baseline.

Сравните результаты моделей между собой и объясните возможные причины различий.

Просто написать: «Gradient Boosting оказался лучше» недостаточно. Попробуйте связать результат с особенностями данных и самих алгоритмов.

Feature importance

Анализ важности признаков — **обязательная часть** лабораторной работы.

Для моделей, позволяющих получить feature importance, необходимо:

1. получить значения важности признаков;
2. визуализировать их;
3. выделить наиболее важные признаки;
4. сравнить результаты разных моделей;
5. сопоставить их с результатами исследовательского анализа данных.

Ответьте на вопрос:

Можно ли на основании feature importance утверждать, что изменение данного признака является причиной изменения качества вина? Почему?

Анализ ошибок

Хорошее значение итоговой метрики ещё не означает, что модель работает одинаково хорошо на всех объектах.

Для лучшей модели исследуйте ошибки предсказания.

Необходимо:

- посмотреть распределение ошибок;
- найти объекты с наиболее крупными ошибками;
- сравнить истинные и предсказанные значения quality;
- проверить, одинаково ли хорошо модель работает для разных значений quality.

Выберите несколько объектов, на которых модель ошиблась особенно сильно, и попробуйте объяснить возможную причину.

Подумайте, почему модель может хуже предсказывать редко встречающиеся значения quality.