

Практический кейс: «Тиммейт-Детектор: ML для поиска руинеров в Dota 2»

Контекст

Киберспортивная организация готовится к квалификациям на The International. У них есть данные о 100 000 матчей пабликов и тренировочных игр. Проблема: в командах постоянно попадают **руинеры** — игроки, которые намеренно или случайно портят игру: фидят, не покупают варды, плачут пятого керри, уходят AFK на 10-й минуте.

Скаут-отдел тратит кучу времени на просмотр реплеев. Они хотят ML-модель, которая по данным матча определяет **вероятность того, что игрок — руинер**. И главное: модель должна **объяснять**, почему она так решила — чтобы тренер за 10 секунд понял, что сказать игроку на разборе.

Роль студента

Вы — Junior Data Scientist в аналитическом отделе киберспортивной организации. Вам нужно построить прототип модели, которая находит руинеров, и защитить её перед «главным тренером» (преподавателем).

Вводные данные

Синтетический датасет на основе открытых данных Dota 2 (OpenDota API) или сгенерированный.

Признаки (Features)

- `match_id` — ID матча
- `player_id` — ID игрока
- `hero_id` — герой, за которого играл
- `role` — позиция (1–5)
- `gpm` — gold per minute
- `xpm` — experience per minute
- `last_hits` — добытые крипы

- `denies` — денаи
- `hero_damage` — урон по героям
- `tower_damage` — урон по строениям
- `wards_placed` — поставлено вардов
- `wards_destroyed` — уничтожено вардов
- `deaths` — смерти
- `kills` — убийства
- `assists` — ассисты
- `afk_time` — время в AFK (секунды)
- `smoke_uses` — использовано смоков
- `buyback_count` — количество байбэков
- `courier_kills` — убийства курьеров
- `runes_taken` — подобранные руны
- `net_worth` — итоговое золото
- `target (is_ruiner)` — целевая переменная (1 — руинер, 0 — норма)

Дисбаланс классов: ~5% руинеров.

Задания для студентов (Этапы решения)

Этап 1. Разведочный анализ (EDA) и работа с дисбалансом (15%)

Проанализировать распределение целевого признака и числовых признаков.

Вопрос для подумать: Правда ли, что все руинеры — это игроки с низким GPM? А если у человека просто плохой матч? Как отличить «плохую игру» от «руинерства»?

Предложить стратегию работы с дисбалансом. Обосновать: SMOTE, class weights, пороговая классификация или что-то ещё. **Важно:** не использовать SMOTE слепо — подумать, какие признаки синтетически генерировать нельзя (например, `afk_time` не может быть отрицательным, а `deaths` не может быть 0.5).

Этап 2. Генерация признаков (Feature Engineering) (20%)

Создать минимум 3 новых признака, которые помогут модели. Примеры:

- **KDA** = $(\text{kills} + \text{assists}) / \max(\text{deaths}, 1)$ — классика, но работает.
- **Ward Efficiency** = $\text{wards_placed} / (\text{net_worth} / 1000)$ — сколько вардов на тысячу золота. Руинеры часто экономят на вардах.
- **AFK Ratio** = $\text{afk_time} / \text{duration}$ — доля времени в AFK.
- **Death Timing** = $\text{deaths} / (\text{game_duration} / 10)$ — сколько смертей за каждые 10 минут.
- **Role Mismatch** = флаг, если игрок на позиции 5 купил предметы для керри (например, Battle Fury на 20-й минуте).
- **Smoke per Minute** = $\text{smoke_uses} / (\text{game_duration} / 60)$.
- **Buyback Waste** = $\text{buyback_count} / \text{deaths}$ — если байбэков больше, чем смертей, это странно.

Бизнес-смысл: тренеру важно не просто «модель сказала руинер», а «модель сказала руинер, потому что у него 0 вардов за 40 минут и AFK 15 минут».

Этап 3. Моделирование и выбор метрик (25%)

Обучить базовую модель (Логистическая регрессия) и бустинг (CatBoost / XGBoost / LightGBM).

Важно: не использовать Accuracy и ROC-AUC как основные метрики. Обосновать выбор **PR-AUC (Average Precision)** или **F2-score**.

Почему F2? Потому что для тренера важнее не пропустить руинера (Recall), чем ошибочно обвинить нормального игрока (Precision). Но и совсем без Precision нельзя — иначе модель будет называть руинерами всех.

Этап 4. Бизнес-оптимизация (Cost-Sensitive Learning) (20%)

Матрица издержек:

- **False Positive (ложное обвинение):** Тренер тратит время на разбор невинного игрока (30 минут = 1000 руб.) + игрок обижается и уходит из команды (упущенная выгода 10 000 руб.). **Итого: -11 000 руб.**
- **False Negative (пропуск руинера):** Команда проигрывает важный матч из-за руинера. Потеря призовых и репутации. **Итого: -50 000 руб.** (или $\text{match_prize} * 1.5$).
- **True Positive:** тренер вовремя разобрался, руинера кикнули, команда выиграла. **+5 000 руб.**
- **True Negative:** всё хорошо. **0 руб.**

Задача: найти оптимальный порог отсечения вероятности, при котором суммарный финансовый убыток организации минимален. Построить график зависимости убытка от порога.

Вопрос для подумать: что если руинер — это тиммейт, который просто играет плохо, но старается? Как модель должна это учитывать? (Ответ: это не руинер, это низкий skill. Модель должна различать.)

Этап 5. Интерпретируемость (Explainable AI) (20%)

Бизнес требует объяснимости.

1. С помощью **SHAP** (или LIME) рассчитать вклад признаков для 5 конкретных игроков из тестовой выборки, которых модель пометила как руинеров (высокий FR или TP).
2. Сформулировать «Код причины» для тренера. Например:
 - «Код 322: *AFK > 20% времени + 0 вардов за игру + 15 смертей за 30 минут*»
 - «Код 404: *Role Mismatch — позиция 5 купил Battle Fury на 25-й минуте*»
 - «Код 228: *Смерти в первые 10 минут > 10 + курьер не убит ни разу*»

Важно: код должен быть понятен тренеру без ML-образования. И желательно смешной, чтобы разрядить обстановку на разборе.

Формат сдачи и критерии оценки

Студенты сдают работу в формате **Jupyter Notebook** и **Презентации для бизнеса** (на 5–7 минут).

Критерии оценки (100 баллов):

1. **Код и ML-пайплайн (30 б):** чистота кода, корректность кросс-валидации (использование `TimeSeriesSplit` или стратификации, чтобы не было утечек из будущего), адекватная работа с дисбалансом.
2. **Бизнес-логика (30 б):** правильный расчёт матрицы издержек, нахождение оптимального порога, перевод метрик ML на язык денег (рубли).
3. **Интерпретируемость (20 б):** корректное применение SHAP, понятные выводы для бизнеса.
4. **Защита/Презентация (20 б):** умение объяснить нетехническому заказчику (преподавателю в роли главного тренера), почему выбрана именно эта модель и как она сэкономит деньги и нервы.

Бонус: идеи для «Кода причины»

- **Код 322:** «AFK > 20% времени. Подозрение на просмотр TikTok во время игры.»
- **Код 404:** «Role Mismatch. Позиция 5 купил Battle Fury. Тренер, поговорите с ним.»
- **Код 228:** «Смерти в первые 10 минут > 10. Это не фид, это кормление врагов.»
- **Код 1337:** «0 вардов за 40 минут. Даже у крипов есть варды. А у него нет.»
- **Код 777:** «Байбэков больше, чем смертей. Как? Просто как?»
- **Код 555:** «Курьер не убит ни разу. Он вообще играл?»